

Conteo automático de capítulos de girasol para asistencia en la estimación de rendimiento agrícola

Pablo Salvagni
Buenos Aires, Argentina
psalvagni@gmail.com

Rodrigo Parra
Sydney, Australia
parra.rodrigo.n@gmail.com

Federica Pavese
Mendoza, Argentina
federica.pavese@gmail.com

Abstract—La estimación temprana del rendimiento agrícola constituye una herramienta fundamental para la planificación logística y la toma de decisiones en cultivos extensivos. En el caso del girasol, el conteo de capítulos florales permite obtener una aproximación directa del rendimiento potencial por unidad de superficie, aunque actualmente suele realizarse mediante relevamientos manuales y técnicas de muestreo estadístico que presentan limitaciones de precisión y escalabilidad.

En este trabajo se propone un sistema de detección y conteo automático de capítulos de girasol basado en modelos de detección de objetos de la familia YOLO. Se realizó un proceso de fine-tuning sobre múltiples arquitecturas preentrenadas utilizando un dataset público compuesto por 4286 imágenes anotadas. Adicionalmente, se evaluó la influencia de distintas configuraciones de entrenamiento y la variabilidad asociada a diferentes semillas, con el objetivo de analizar tanto el desempeño como la robustez de los modelos obtenidos.

Los resultados muestran que la configuración YOLO11s entrenada con SGD alcanzó el mejor desempeño global, obteniendo una precisión de 0.871, un recall de 0.838, un mAP50 de 0.913 y un mAP50-95 de 0.5782. Finalmente, el modelo seleccionado fue validado mediante inferencia sobre imágenes y secuencias de video capturadas por dron, demostrando su capacidad para detectar y contabilizar capítulos de girasol en escenarios reales.

Index Terms—Agricultura de precisión, Visión por Computadora, Detección de Objetos, YOLO, Deep Learning, Sunflower Detection.

I. INTRODUCCIÓN

La estimación del rendimiento agrícola es una de las tareas más críticas en la gestión de cultivos extensivos. En el caso particular del girasol, el conteo de capítulos constituye un indicador directo del rendimiento potencial por unidad de superficie. Esta información, relevada en etapas tempranas del ciclo productivo, permite a productores y acopiadores anticipar volúmenes de cosecha, optimizar la logística de almacenamiento y tomar decisiones comerciales con mayor certeza.

Sin embargo, la metodología tradicional de conteo se basa en muestreos estadísticos realizados por personal en campo: operarios recorren el lote seleccionando secciones representativas y contando manualmente los capítulos visibles. Este procedimiento, aunque extendido en la práctica agronómica, presenta limitaciones estructurales que comprometen su escalabilidad y precisión. Este procedimiento es lento, costoso, susceptible a errores humanos y difícilmente escalable a grandes extensiones.

La incorporación de drones y cámaras de alta resolución en la agricultura de precisión abrió una nueva posibilidad: capturar imágenes aéreas y terrestres del cultivo a bajo costo operativo y con gran cobertura espacial.

Es en este contexto donde la Visión por Computadora ofrece una solución natural. Los modelos modernos de detección de objetos, basados en redes neuronales convolucionales profundas, son capaces de localizar y contar instancias de objetos de interés en imágenes con alta precisión y a velocidades compatibles con el procesamiento en tiempo real. En particular, la familia de modelos YOLO (You Only Look Once) se ha consolidado como un estándar para tareas de detección donde se requiere un balance entre precisión y eficiencia computacional, siendo ampliamente adoptada en aplicaciones de borde (edge computing), como dispositivos embebidos y drones autónomos.

Trabajos recientes confirman la viabilidad de este enfoque en cultivos similares [3], [4], mostrando que los modelos de detección basados en aprendizaje profundo pueden alcanzar niveles de precisión elevados en condiciones de campo y habilitar sistemas de monitoreo agrícola a escala.

El presente trabajo propone el desarrollo de un sistema de detección y conteo automático de capítulos de girasol mediante técnicas de visión por computadora y aprendizaje profundo. Para ello, se realizó un estudio experimental basado en modelos de detección de objetos de la familia YOLO, utilizando técnicas de transferencia de aprendizaje sobre un dataset público de imágenes anotadas.

Se evaluaron distintas arquitecturas y configuraciones de entrenamiento, así como la influencia de múltiples inicializaciones aleatorias. Finalmente, el modelo seleccionado fue validado sobre imágenes y secuencias de video capturadas por dron para explorar su aplicación en escenarios de agricultura de precisión.

II. DATASET Y ANÁLISIS EXPLORATORIO

A. Descripción del dataset

El conjunto de datos utilizado en este trabajo corresponde al Sunflower Computer Vision Dataset [1], disponible públicamente a través de la plataforma Roboflow, y descrito en detalle en [2]. El dataset está compuesto por 4286 imágenes de capítulos de girasol capturadas mediante dron en condiciones reales de campo y anotadas manualmente mediante cajas delimitadoras (bounding boxes).

Las imágenes se encuentran distribuidas en tres subconjuntos independientes: entrenamiento, validación y prueba. La partición original contempla 3429 imágenes para entrenamiento (80%), 428 imágenes para validación (10%) y 429 imágenes para evaluación final (10%).

El conjunto de datos incluye dos categorías originales: *Sunflower*, correspondiente a capítulos observados de frente, y *Backside-Sunflower*, correspondiente a capítulos observados desde su cara posterior.

B. Distribución de clases

El análisis exploratorio mostró una alta variabilidad en la cantidad de objetos por imagen, así como diferencias en tamaño aparente, orientación y nivel de oclusión de los capítulos.

C. Análisis de anotaciones y densidad de objetos

El análisis de las anotaciones mostró una elevada variabilidad en la cantidad de capítulos presentes por imagen. Mientras que algunas imágenes contienen únicamente unas pocas instancias visibles, otras presentan decenas o incluso más de un centenar de capítulos distribuidos en diferentes escalas y niveles de oclusión.

A partir del análisis estadístico realizado sobre las anotaciones se observó un promedio aproximado de 69 capítulos por imagen.

El dataset presenta variaciones de iluminación, perspectiva, distancia de captura, tamaño aparente de los objetos y densidad de vegetación, constituyendo un escenario desafiante y representativo para evaluar la robustez de modelos de detección en aplicaciones de agricultura de precisión.



Fig. 1. Ejemplos representativos del dataset utilizado, mostrando distintas densidades de capítulos de girasol presentes en las imágenes.

III. METODOLOGÍA

A. Preprocesamiento del dataset

Las clases originales *Sunflower* y *Backside-Sunflower* fueron fusionadas en una única categoría, dado que la orientación del capítulo no resulta relevante para la tarea de conteo. Las imágenes se procesaron en el formato requerido por YOLO, manteniendo las anotaciones originales y la partición en entrenamiento, validación y prueba.

B. Arquitecturas evaluadas

Se evaluaron modelos de las familias YOLOv8, YOLO11 y YOLO26, considerando variantes de diferente complejidad computacional. Todas las configuraciones fueron inicializadas con pesos preentrenados sobre COCO y ajustadas mediante transferencia de aprendizaje sobre el dataset de girasoles.

C. Configuración experimental

Se estudiaron distintas configuraciones de entrenamiento. Posteriormente se optó por definir la cantidad de épocas y otros parámetros, particularmente, el optimizador como SGD (Stochastic Gradient Descent), debido a su comportamiento estable y ampliamente documentado en tareas de visión por computadora [5]. El batch size se ajustó según las restricciones de memoria de la GPU.

Para evaluar la reproducibilidad se realizaron cinco corridas independientes con distintas semillas aleatorias. Todas las métricas de entrenamiento y validación fueron registradas mediante la plataforma Weights & Biases (W&B), facilitando el monitoreo y la comparación sistemática de los experimentos.

TABLE I
HIPERPARÁMETROS COMUNES DE ENTRENAMIENTO

Parámetro	Valor
Optimizador	SGD
Learning rate (lr0)	0.01
Momentum	0.937
Weight decay	0.0005
Epochs	50
Batch size	8
Image size	640

D. Banco de pruebas

Los experimentos fueron realizados en distintas plataformas, entre ellas Colab, y computadoras personales con distintas GPU. En cuanto al entrenamiento se utilizó un equipo con una GPU NVIDIA RTX 3080 Mobile y un procesador Intel i7 11800H con 32 GB de Ram.

E. Métricas de evaluación

El desempeño de los modelos fue evaluado mediante las métricas estándar de detección de objetos:

- **Precision:** cuantifica la proporción de detecciones correctas respecto del total de detecciones realizadas por el modelo:

$$\text{Precision} = \frac{TP}{TP + FP}$$

donde TP (verdaderos positivos) son las detecciones que coinciden con un objeto real y FP (falsos positivos) son las detecciones que no corresponden a ningún objeto real.

- **Recall:** mide la capacidad del detector para identificar los objetos presentes en la imagen:

$$\text{Recall} = \frac{TP}{TP + FN}$$

donde FN (falsos negativos) son los objetos reales que el modelo no logró detectar.

- **AP (Average Precision):** para un umbral de IoU dado, se construye la curva Precision-Recall variando el umbral de confianza de las detecciones, y el AP se define como el área bajo dicha curva. El **mAP** (*mean Average Precision*) corresponde al promedio del AP sobre todas las clases del problema.

- **mAP50**: corresponde al mAP calculado utilizando un umbral de Intersección sobre Unión (*Intersection over Union*, IoU) de 0.50. Una detección se considera correcta si el solapamiento entre la caja predicha y la caja real (IoU) es de al menos un 50%.
- **mAP50-95**: extiende este criterio promediando el AP sobre diez umbrales de IoU equiespaciados entre 0.50 y 0.95 (paso 0.05).

Debido a que el objetivo es detectar la cantidad de capítulos de girasol, las métricas más importantes a analizar serán una combinación de recall, precisión y mAP50. Si bien mAP50-95 es relevante en muchos ámbitos de la detección de objetos, en este caso particular el foco no está puesto en la precisión de las cajas de detección sino en la capacidad de detectar los capítulos por lo que mAP50 resulta más relevante.

IV. RESULTADOS EXPERIMENTALES

A. Comparación entre arquitecturas

Los resultados obtenidos evidenciaron que las 6 configuraciones evaluadas presentaron resultados muy cercanos para todas las métricas analizadas aunque se puede distinguir algunas pequeñas diferencias. La primera observación es que los modelos de tamaño *s* presentaron consistentemente una mejora respecto de el mismo modelo de tamaño *n*, aunque estas diferencias son realmente pequeñas (del orden del 2%).

En cuanto a la variabilidad entre semillas, la mayoría de las configuraciones presentan desvíos estándar extremadamente bajos (del orden de 0.000–0.002 en mAP50), lo que sugiere que el proceso de entrenamiento es altamente reproducible. La excepción notable es YOLOv8s, cuyo mAP50 presenta un desvío de ± 0.018 , y que también muestra el mayor desvío en recall (± 0.014). No está completamente clara la razón de este aumento pero se produjo en la última época de uno de los entrenamientos, por lo que es probable que se deba simplemente a una inestabilidad para esa semilla en particular.

Respecto a la comparación entre modelos, YOLO11s se destaca como la configuración con mejor desempeño en las tres métricas (mAP50=0.913, precisión=0.871, recall=0.838), seguida de cerca por YOLOv8s y YOLOv26s. Dado que los desvíos estándar de YOLO11s son mínimos (± 0.001), la diferencia con respecto a YOLOv8n, YOLOv11n y YOLOv26n (que rondan mAP50=0.885–0.901) parece ser real y no atribuible al ruido entre semillas, ya que los intervalos de media $\pm$ std prácticamente no se superponen. En cambio, la diferencia entre YOLOv11s, YOLOv8s y YOLOv26s (0.903–0.913) es más sutil, y considerando la variabilidad de YOLOv8s, no puede descartarse que esa diferencia esté dentro del ruido esperable.

Un resultado a destacar observado en la Tabla II es el bajo rendimiento que se obtuvo con el modelo YOLO26n, el cual está significativamente por debajo en todas las métricas respecto de los otros modelos del mismo tamaño. A modo de verificación se cambió el optimizador a Adam con los parámetros por defecto y si bien los resultados mejoraron, continuaron estando por debajo de las otras variantes del mismo tamaño.

TABLE II
COMPARACIÓN DE MODELOS BAJO CONDICIONES CONTROLADAS (MEDIA $\pm$ DESVÍO ESTÁNDAR, 5 SEMILLAS)

Configuración	mAP50	Precision	Recall
YOLOv8n	0.901 $\pm$ 0.000	0.861 $\pm$ 0.002	0.830 $\pm$ 0.002
YOLOv8s	0.903 $\pm$ 0.018	0.866 $\pm$ 0.001	0.833 $\pm$ 0.014
YOLOv11n	0.900 $\pm$ 0.000	0.860 $\pm$ 0.003	0.825 $\pm$ 0.002
YOLOv11s	0.913 $\pm$ 0.001	0.871 $\pm$ 0.001	0.838 $\pm$ 0.002
YOLOv26n	0.885 $\pm$ 0.000	0.839 $\pm$ 0.002	0.810 $\pm$ 0.002
YOLOv26s	0.906 $\pm$ 0.000	0.859 $\pm$ 0.002	0.831 $\pm$ 0.002




Fig. 2. Evolución de mAP50 durante el entrenamiento.




Fig. 3. Evolución de recall durante el entrenamiento.

B. Análisis de rendimiento

Dado que las métricas de detección de los modelos resultaron relativamente similares entre sí, se realizaron pruebas de rendimiento para determinar si existían diferencias significativas en tiempo de inferencia que justificaran preferir un modelo sobre otro.

Como se observa en la Tabla III, todos los modelos superan los 100 FPS con el hardware utilizado (RTX 3060 Ti), siendo YOLOv8n el más rápido con 126.8 FPS y YOLOv26s el más lento con 101.7 FPS. Se aprecia además una relación directa entre el tamaño del modelo (cantidad de parámetros y GFLOPs) y el tiempo de inferencia: las variantes *n* son consistentemente más rápidas que las *s* dentro de cada arquitectura,

TABLE III
TIEMPO DE INFERENCIA Y FPS POR MODELO (IMGSZ=640, BATCH=1, RTX 3060 Ti)

Modelo	Params (M)	GFLOPs	Tiempo (ms)	FPS
YOLOv8n	3.16	8.9	7.89 ± 0.83	126.8
YOLOv8s	11.17	28.8	8.64 ± 0.44	115.7
YOLOv11n	2.62	6.6	8.54 ± 0.94	117.1
YOLOv11s	9.46	21.7	9.15 ± 0.49	109.3
YOLOv26n	2.57	6.1	9.54 ± 0.59	104.9
YOLOv26s	10.01	22.8	9.83 ± 0.43	101.7

y las arquitecturas más recientes (YOLOv11, YOLOv26) no necesariamente implican menor costo computacional frente a YOLOv8.

La Figura 4 muestra el rendimiento relativo de cada modelo respecto del más rápido (YOLOv8n), lo que permite visualizar de forma más directa la magnitud de las diferencias: incluso el modelo más lento (YOLOv26s) opera a aproximadamente el 84% de la velocidad del más rápido.




Fig. 4. Rendimiento relativo de los modelos respecto al más rápido (YOLOv8n).

Si bien estos valores de FPS son más que suficientes para procesar video a 30 FPS, este análisis resulta relevante porque, ante un aumento en la resolución de entrada o un despliegue en hardware con menores recursos (por ejemplo, un dispositivo embebido o un dron), la velocidad de inferencia podría disminuir significativamente. En ese escenario, las diferencias observadas aquí —aunque pequeñas en el hardware actual— podrían volverse determinantes a la hora de elegir un modelo.

C. Selección del modelo final

Entre todas las configuraciones evaluadas, YOLOv11s obtuvo el mejor desempeño global. Esta configuración alcanzó una precisión de 0.871, un recall de 0.838, un mAP50 de 0.913 y un mAP50-95 de 0.5782, superando al resto de los modelos analizados en la métrica principal de evaluación.

Considerando lo mencionado anteriormente respecto del rendimiento de los modelos, **YOLOv11s fue la configuración seleccionada** para las etapas posteriores de cálculo del umbral de confianza, validación visual, conteo automático e inferencia sobre imágenes y secuencias de video.

Si bien al comparar estos resultados con otros trabajos como [3], en el cual también se hace uso de YOLOv11 y se reportan valores superiores (mAP50=0.95, precision=0.84, recall=0.95), estas diferencias deben interpretarse con cautela. Dicho trabajo fue evaluado sobre un dataset considerablemente más pequeño y homogéneo (1290 recortes provenientes de 215 imágenes capturadas sobre una única parcela experimental de 900 m²), bajo condiciones de vuelo, iluminación y altura controladas, lo cual favorece la obtención de métricas más altas pero limita la generalización a escenarios de campo más diversos. En contraste, el dataset utilizado en este trabajo presenta una amplia variabilidad de condiciones, escalas y densidades de objetos, lo que constituye un escenario de evaluación más exigente. Además, en nuestro caso se incluyen también capítulos observados desde su cara posterior (capítulos “dados vuelta”), categoría que no es contemplada en el trabajo de referencia y que añade una dificultad adicional a la tarea de detección. Adicionalmente, dicho trabajo no especifica la variante de tamaño de YOLOv11 empleada (n, s, m, l o x), lo cual dificulta una comparación directa en términos de complejidad computacional y capacidad del modelo.

Por otro lado, el trabajo [4] utiliza el mismo dataset que el empleado en este estudio y reporta para YOLOv11s resultados prácticamente equivalentes a los obtenidos aquí (precisión=0.8752, recall=0.8520, mAP50=0.9271, mAP50-95=0.6078, sobre 3 corridas), lo cual constituye una validación cruzada de los resultados presentados.

D. Determinación del umbral de confianza

La elección del umbral de confianza (`conf`) no es un detalle menor de implementación ya que un umbral demasiado bajo acepta detecciones poco confiables, aumentando los falsos positivos (sobreestimación del rendimiento), mientras que un umbral demasiado alto descarta detecciones válidas, aumentando los falsos negativos (subestimación del rendimiento). De hecho, la propia librería Ultralytics realiza un procedimiento conceptualmente similar de forma interna: al finalizar el entrenamiento, construye curvas de precision, recall y F1 a lo largo de 1000 umbrales de confianza interpolados sobre la curva precision-recall, y reporta como `precision` y `recall` los valores correspondientes al punto de máximo F1 (suavizado). Sin embargo, ese cálculo está pensado para resumir el desempeño general del modelo durante el entrenamiento, y no corresponde a un umbral fijo utilizable en inferencia.

Por ello, se replicó ese mismo criterio de forma explícita y adaptada al problema realizando un barrido sobre el rango de valores de `conf`, ejecutando inferencia real sobre la totalidad del set de validación y midiendo precision, recall y F1 de forma agregada para cada valor. La Figura 5 muestra la evolución de estas tres métricas en función del umbral: a medida que `conf` aumenta, la precision crece de forma monótona mientras que el recall decrece, y el punto donde el F1 alcanza su máximo representa el mejor compromiso entre ambos criterios. Este valor de `conf` es el que se adoptó como umbral de operación para el conteo de capítulos de girasol.




Fig. 5. Precision, recall y F1 en función del umbral de confianza. La línea punteada indica el punto de máximo F1.

V. VALIDACIÓN VISUAL E INFERENCIA

A. Detección y conteo sobre imágenes

La validación del modelo seleccionado se realizó mediante inferencia sobre imágenes del conjunto de validación, comparando la cantidad de capítulos detectados con las anotaciones del ground truth.

Los resultados evidenciaron un desempeño satisfactorio en imágenes con baja y media densidad de objetos. En escenarios con alta densidad y mayores niveles de oclusión se observaron diferencias más significativas entre el conteo manual y el automático.

TABLE IV
COMPARACIÓN ENTRE CONTEO MANUAL Y DETECCIÓN AUTOMÁTICA

Imagen	Etiquetados	Detectados	Diferencia
IMG01	11	11	0
IMG02	68	62	-6
IMG03	37	46	9
IMG04	36	31	-5
IMG05	83	83	0
IMG06	24	26	2
IMG07	48	51	3
IMG08	34	41	7
IMG09	38	39	1
IMG10	159	139	-20
Total	538	529	-9

La comparación entre el conteo manual y la detección automática muestra una cobertura aproximada del 98% respecto del ground truth (529 detecciones sobre 538 capítulos etiquetados). Las mayores diferencias se observaron en imágenes con alta densidad de capítulos, donde las oclusiones y superposiciones dificultan tanto la detección de todos los objetos presentes como la correcta delimitación de cada capítulo individual.

Los errores observados se concentran principalmente en situaciones de alta densidad de objetos y oclusiones parciales, donde algunos capítulos no logran ser detectados por el modelo, lo cual se puede apreciar en la imagen 6. Aun así,




Fig. 6. Ejemplo de detección sobre imagen del set

el comportamiento global del detector resulta consistente con las métricas obtenidas durante el proceso experimental.

B. Aplicación de inferencia desarrollada

Con el fin de explorar la aplicabilidad práctica del sistema desarrollado, se implementó una interfaz interactiva basada en Streamlit que permite realizar inferencias sobre imágenes de campo de manera sencilla e intuitiva.

La aplicación recibe una imagen como entrada y ejecuta automáticamente el modelo YOLO11s seleccionado durante la etapa experimental. Como salida, se muestran las detecciones realizadas mediante cajas delimitadoras y el conteo total de capítulos identificados en la imagen.

Detector y Contador de Girasoles

Esta herramienta utiliza un modelo YOLOv11s5D entrenado específicamente para detectar capítulos de girasol en imágenes y videos tomadas a campo. Sube una foto o video y el sistema registrará la métrica automáticamente.




Fig. 7. Interfaz desarrollada para la detección y conteo automático de capítulos de girasol.

La Figura 7 presenta un ejemplo de funcionamiento de la herramienta desarrollada. En este caso, el sistema detectó 83 capítulos de girasol sobre una imagen capturada en condiciones reales de campo.

Los resultados obtenidos demuestran la viabilidad de integrar modelos de detección de objetos en aplicaciones prácticas destinadas al monitoreo agrícola y al relevamiento automatizado de cultivos extensivos.

C. Limitaciones observadas

Si bien los resultados obtenidos fueron satisfactorios, se identificaron limitaciones en regiones con alta densidad de

capítulos, donde las oclusiones y superposiciones dificultan la detección. Asimismo, variaciones extremas de iluminación y diferencias significativas de escala pueden afectar el desempeño del modelo.

Si bien las pruebas realizadas demostraron la capacidad del sistema para detectar y contabilizar capítulos de girasol en condiciones reales de campo, será necesario ampliar la evaluación sobre distintos lotes y condiciones ambientales para validar completamente su robustez.

D. Trabajo futuro

A partir de los resultados obtenidos, se identifican diversas líneas de trabajo futuro orientadas a avanzar hacia un sistema de monitoreo aplicable en escenarios productivos reales. En primer lugar, se propone evaluar el desempeño del modelo sobre dispositivos embebidos de la familia NVIDIA Jetson, con el objetivo de analizar su viabilidad para ejecutar inferencia directamente a bordo de un dron. Asimismo, se plantea la adquisición de un conjunto propio de imágenes capturadas en campo, que permita ampliar la evaluación y analizar la capacidad de generalización del modelo sobre datos independientes. Finalmente, resulta de interés explorar sistemas de vuelo autónomo que integren la captura de imágenes con el procesamiento e inferencia en tiempo real, avanzando hacia soluciones escalables para agricultura de precisión.

VI. CONCLUSIONES

En este trabajo se desarrolló un sistema de detección y conteo automático de capítulos de girasol basado en modelos de visión por computadora de la familia YOLO. A partir de un conjunto de datos público compuesto por imágenes anotadas manualmente, se evaluaron múltiples arquitecturas, configuraciones de entrenamiento y semillas aleatorias para analizar el desempeño y la robustez de los modelos obtenidos.

Los resultados experimentales demostraron que los enfoques basados en detección de objetos permiten identificar capítulos de girasol con un elevado nivel de precisión, incluso en escenarios caracterizados por variaciones de iluminación, perspectiva y densidad de vegetación. El análisis comparativo realizado mostró que YOLOv11s obtuvo el mejor desempeño global, aunque por un margen reducido respecto del resto de las configuraciones evaluadas. No obstante, dado que esta diferencia se mantuvo de forma consistente a lo largo de las 5 corridas independientes realizadas con cada modelo, se la considera una ventaja real y no atribuible al ruido entre semillas, por lo que YOLOv11s entrenado mediante SGD fue la configuración seleccionada, alcanzando una precisión de 0.871, un recall de 0.838, un mAP50 de 0.913 y un mAP50-95 de 0.5782.

El estudio de variabilidad entre semillas evidenció un comportamiento consistente y reproducible. Asimismo, las pruebas de inferencia sobre imágenes de campo y la implementación de una herramienta interactiva demostraron la factibilidad de aplicar este tipo de soluciones en escenarios reales de agricultura de precisión. Resulta importante mencionar que los resultados mejoran en los casos en que las imágenes no tienen

un horizonte repleto de capítulos, evidenciando la importancia de desarrollar un método de obtención de imágenes que garantice esto.

Si bien se observó una pequeña ventaja de las variantes s respecto de las n en todas las arquitecturas evaluadas, esta diferencia fue del orden del 1-2% en mAP50, precisión y recall, por lo que en términos generales todos los modelos presentaron un comportamiento similar. Esto implica que, ante la necesidad de mejorar el rendimiento computacional (por ejemplo, para su despliegue en dispositivos embebidos o de menor capacidad), podría optarse por un modelo de tamaño n sin incurrir en una pérdida significativa de precisión ni de recall, lo cual brinda un margen de flexibilidad considerable a la hora de balancear exactitud y eficiencia según el escenario de aplicación.

Si bien el sistema presentó algunas dificultades en imágenes con alta densidad de capítulos y elevados niveles de oclusión, los resultados obtenidos muestran el potencial de las técnicas modernas de detección de objetos para automatizar tareas tradicionalmente realizadas de forma manual. Las líneas de trabajo futuro propuestas en la sección anterior, junto con la exploración de estrategias de seguimiento y deduplicación, permitirían avanzar hacia un sistema de conteo robusto a escala de campo completo.

REFERENCES

- [1] Sunflower Computer Vision Dataset. <https://universe.roboflow.com/raiyar8018/sunflower-mn2cr>
- [2] M. S. Hossain, M. R. A. Rashid, M. Fahim, Tahzib-E-Alindo, M. S. Ali, M. Islam, M. M. Islam, M. H. Ferdous, and N. T. Niloy, "Drone-based dataset of annotated sunflower images from Bangladesh," *Data in Brief*, vol. 59, p. 111417, 2025. <https://doi.org/10.1016/j.dib.2025.111417>
- [3] "Automated Sunflower Head Detection and Yield Estimation from High-Resolution UAV Imagery Using YOLOv11 for Precision Agriculture" *Sustainability*, vol. 18, no. 2, p. 1026, 2026. <https://www.mdpi.com/2071-1050/18/2/1026>
- [4] F. R. Sams, S. K. Supti, S. B. Hamid, R. Junayed, et al., "Real-Time Sunflower Detection Using Semi-Supervised and Self-Supervised Deep Learning for Precision Agriculture," *Smart Agricultural Technology*, vol. 13, p. 101684, 2025. <https://www.sciencedirect.com/science/article/pii/S2772375525009153>
- [5] "A. C. Wilson, R. Roelofs, M. Stern, N. Srebro, and B. Recht, "The Marginal Value of Adaptive Gradient Methods in Machine Learning," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017, pp. 4148–4158." <https://arxiv.org/abs/1705.08292>