

Del Campo al Píxel: Conteo Automático de Girasoles mediante Deep Learning

Estimación temprana de rendimiento agrícola utilizando arquitecturas YOLO en imágenes aéreas.

+ Pablo Salvagni | Rodrigo Parra | Federica Pavese +

0.91



0.92



0.88



0.94



0.92



Motivación



Muestreo tradicional

Relevamiento manual, lento y costoso en horas de trabajo.

Propenso a errores por fatiga visual o simplemente un error humano.

Inviabile como método exhaustivo en cientos de hectáreas (depende de una estimación parcial y con mucha incertidumbre)



Solución digital

Drones que capturan imágenes con gran cobertura espacial a bajo costo

Modelos de Deep Learning detectan y cuentan instancias en tiempo real

Permite reducir costos y planificar siembra, cosecha, logística y comercialización.

EDA - Sunflower Computer Vision Dataset: 4.286 Imágenes

Dataset público → Entrenamiento: 2.429 (80%) / Validación: 428 (10%) / Prueba: 429 (10%)



Densidad BAJA



Densidad MEDIA



Densidad ALTA

Alta variabilidad visual

Los objetos aparecen en diferentes escalas y con distintos grados de superposición, iluminación y perspectiva. Aporta **realismo** y favorece la capacidad de **generalización del modelo**.


Densidad

El análisis estadístico revela un **promedio de 69 capítulos por imagen**, con imágenes que contienen desde pocos objetos hasta más de un centenar.

Preprocesamiento

La distribución de clases muestra un **fuerte desbalance** entre *Backside-Sunflower* y *Sunflower*, por lo que se fusionaron en una única clase, dado que la orientación no resulta relevante para el **conteo**.

Pipeline Experimental




Arquitecturas Evaluadas

Se analizaron variantes de diferente complejidad computacional para encontrar el balance perfecto entre precisión y velocidad.



Parámetros de Entrenamiento:

- **Optimizador:** SGD (Stochastic Gradient Descent) por su estabilidad comprobada.
- **Epocas:** 50
- **Tamaño de Imagen:** 640px
- **Batch Size:** 8




Evaluación

- Pruebas sobre YOLO v8, v11 y v26 para las variantes n y s
- 5 entrenamientos con distintas semillas
- Optimizador SGD
- Métricas más importantes: recall, map50, precision



Análisis de rendimiento



Modelo	Params (M)	GFLOPs	Tiempo (ms)	FPS
YOLOv8n	3.16	8.9	7.89 ± 0.83	126.8
YOLOv8s	11.17	28.8	8.64 ± 0.44	115.7
YOLOv11n	2.62	6.6	8.54 ± 0.94	117.1
YOLOv11s	9.46	21.7	9.15 ± 0.49	109.3
YOLOv26n	2.57	6.1	9.54 ± 0.59	104.9
YOLOv26s	10.01	22.8	9.83 ± 0.43	101.7

Comparativa y Resultado de Arquitecturas: (Media)

"YOLO Clash" Matrix


Modelo	Params	mAP50	Precision	Recall	FPS
YOLOv8n	3.16M	0.901	0.861	0.830	126.8
YOLOv8s	11.17M	0.903	0.866	0.833	115.7
YOLO11n	2.62M	0.900	0.860	0.825	117.1
YOLO11s	9.46M	0.913	0.871	0.838	109.3
YOLO26n	2.57M	0.885	0.839	0.810	104.9
YOLO26s	10.01M	0.906	0.859	0.831	101.7

Modelo
Seleccionado

La variante YOLO11s demostró la mejor precisión global con desvíos estándar mínimos (± 0.001), superando a modelos más recientes y pesados (v26s).

Calibración del Modelo

El Umbral de Confianza



1

Falsos Negativos (Umbral Alto):

Descarte de detecciones válidas, con Riesgo de Subestimación del rendimiento

0.4

El Punto Óptimo (Conf = 0.40)

Maximización del score F1 logra el equilibrio perfecto adoptado para el conteo operativo. (Inferencia)

0

Falsos Positivos (Umbral Bajo):

Detecciones poco confiables, con Riesgo de Sobreestimación del rendimiento comercial.


Validación en el Campo: Cobertura y Limitaciones

El análisis empírico determinó que un **Confidence Threshold de 0.4** ofrece el mejor compromiso entre capacidad de detección y precisión visual.

Matriz de Confusión (Validación):
28,311 Verdaderos Positivos
capturados exitosamente.

Reducida proporción de Falsos Negativos (7.840), justificable por las oclusiones extremas presentes en el dataset.

Falsos Positivos: mínimos frente al fondo del dataset.



Key Findings

Cobertura del 83%

Alta correspondencia con el ground truth (conteo manual)

Baja Tasa de Falsos Negativos


Evidenciado por la matriz de confusión, el modelo identificar confiablemente los capítulos presentes.

Zonas de Fricción

Las discrepancias de conteo ocurren en regiones de alta densidad. La superposición parcial y las oclusiones siguen siendo el principal desafío agronómico.

Inferencia en el mundo Real

Del modelo a la práctica - Interfaz de Monitoreo



Para validar el sistema, se desarrolló una interfaz interactiva en **Streamlit** que convierte una captura aérea cruda en un inventario de rendimiento, acercando la agricultura tradicional a la agricultura de precisión.

Ejemplo de Validación en imagen:

- El sistema logra una cobertura aproximada del **89%** respecto del conteo manual humano (**627 detectados vs 703 etiquetados**).
- Desempeño perfecto en escenarios de densidad baja y media.
- Las diferencias se concentran exclusivamente en imágenes con densidades extremas de ± 140 capítulos, donde el ojo humano también sufre.

Detector y contador de girasoles

El Futuro Autónomo: Próximos Pasos en el Cultivo

Eficacia y flexibilidad:

La arquitectura YOLO demostró gran robustez para el conteo agrícola, destacando las versiones "Nano" por su capacidad de operar en drones sin sacrificar precisión.

Desafíos operativos:

Para minimizar confusiones y lidiar con oclusiones en altas densidades, es un requisito importante estandarizar el ángulo y la captura de las imágenes en el campo.

Proyección a futuro:

El prototipo valida el uso de IA para automatizar el trabajo manual, abriendo paso a la implementación en tiempo real con drones y algoritmos de tracking.

